

2D 이미지 분할과 3D 메쉬 복원을 활용한 시선 기반

파지 자세 생성

도윤서^o, 오승재

경희대학교

ysdoh0209@khu.ac.kr, oreo329@khu.ac.kr

Gaze-Conditioned Grasp Synthesis via 2D Segmentation and 3D Reconstruction

Yunseo Do^o, Seungjae Oh

Kyung Hee University

ysdoh0209@khu.ac.kr, oreo329@khu.ac.kr

요 약

본 연구는 아이트래커를 통해 추출한 1인칭 시점 이미지(egocentric image)와 시선 좌표 정보(gaze point)를 조건으로 하여 사용자가 응시한 물체를 인식하고 3D로 복원한 뒤, 해당 객체에 대한 자연스러운 파지 자세 생성(grasp synthesis)을 수행하는 엔드투엔드 파이프라인을 제안한다. 기존 연구는 시선 정보를 로봇의 파지 대상 선택이나 행동 분류에 활용하는 데 그쳤으며, 이를 3D 복원 및 인간 손 기반 파지 생성까지 연결한 사례는 드물다. 본 연구는 시선 기반 2D 분할-3D 복원-파지 생성 단계를 하나의 흐름으로 통합하였으며, 사용자 평가에서 객체 선택 정확도, 분할 품질, 단계 간 물체 일관성에서 높은 타당성을 보였다. 이를 통해 시선 기반 조작 시스템의 새로운 가능성을 제시한다.

1. 서 론¹

사람은 일상 속에서 무의식적으로 물체를 응시하고, 그에 맞는 손 동작을 통해 상호작용을 수행한다. 이러한 인간의 시선 기반 상호작용은 인간-컴퓨터 상호작용(Human-Computer Interaction)이나 인간-로봇 상호작용(Human-Robot Interaction) 분야에서 중요한 통찰을 제공한다.

현재까지의 시선 기반 상호작용 연구는 주로 특정 단계에 국한되는 경향을 보였다. 첫째, 시선 정보를 활용한 연구들은 대부분 로봇이 파지할 객체를 선택하거나[1], 사용자의 의도를 분류(예: '잡기' vs '보기')하는 데 집중되었다[2]. 이러한 연구들은 시선

정보를 상위 수준의 명령으로 해석하는 데 그쳤다.

둘째, 단일 이미지 기반 3D 객체 복원 기술은 TripoSR[3], Zero-1-to-3[4] 등 혁신적인 모델의 등장으로 큰 발전을 이루었으나, 대부분의 연구는 사용자의 시선 정보와는 독립적으로 수행되어 '어떤 객체를' 복원해야 하는지에 대한 맥락적 접근은 부족했다.

마지막으로, GHOP[5], GraspNet[6] 등 파지 자세 생성(Grasp Synthesis)에 관한 연구들은 주로 정제된 3D 모델 데이터셋을 기반으로 수행되었다. 이는 단일 시점 이미지로부터 복원되어 노이즈가 포함되거나 일부가 누락된 불완전한 상황의 3D 복원에 한계를 가진다.

이처럼 각 기술 요소는 독립적으로 발전해왔으나, 현재까지 (1) 사용자의 시선에서 출발하여 (2) 객체를 분할하고 (3) 단일 이미지로 3D 모델을 복원한 뒤, (4) 해당 모델에 적합한 인간의 손 파지 자세를 생성하는 전 과정을 유기적으로 연결한 엔드투엔드 파이프라인을

* 본 연구는 과학기술정보통신부 및 정보통신기획평가원의 2025년도 SW중심대학사업의 결과로 수행되었음 (2023-0-00042)

제시한 연구는 찾아보기 어렵다. 본 연구는 시선 기반 2D 분할-3D 복원-파지 생성 단계를 하나의 흐름으로 통합하여 시선 기반 조작 시스템의 새로운 가능성을 제시한다.

2. 방법론




그림 1: 전체 파이프라인

본 연구에서는 사용자의 시선을 기반으로, 2D 객체 분할부터 3차원 복원 및 파지 자세 생성을 하나의 연속적인 파이프라인으로 연결하는 시스템을 제안한다. 그림 1은 전체 흐름을 도식화한 것으로, 각 모듈 뿐만 아니라 단계를 자연스럽게 연결하기 위한 후처리 알고리즘이 포함된다.

2.1 시선 신호 추출

사용자의 시선을 실시간으로 추적하기 위해 Pupil Labs Neon[7] 장치를 사용하였으며, 1920x1080 해상도의 1인치 시점 이미지와 함께 시선 좌표를 추출한다. 이 시선 좌표는 후속 분할 단계에서 포인트 프롬프트로 활용된다.

2.2 2D 이미지 분할

앞 단계에서 얻은 1인치 시점 이미지와 시선 좌표를 입력으로 하여 SAM[8] 모델 ViT-H 버전을 통해 사용자가 주목한 객체를 분할한다. 해당 모델은 별도의 학습 없이도 단일 포인트 프롬프트만으로 높은 정확도의 제로샷(zero-shot) 분할이 가능하며, 다양한 종류의 일상 사물에 강인한 성능을 보인다. 생성된 바이너리 마스크(binary mask)를 이용해 원본 이미지에서 배경을 제거하고, 객체 영역만 포함된 RGBA 이미지를 생성하였다. 이 배경이 제거된 이미지는 3D 복원 단계에서 불필요한 노이즈를 최소화하는 역할을 한다.

2.3 단일뷰 3D 복원

3차원 복원을 위해서는 타 모델 대비 빠른 추론 속도와 높은 재현 품질을 가지는 TripoSR[3] 모델을 활용하였다. 배경 제거된 물체 이미지를 해당 모델의 입력으로 사용하여 3D 메시를 복원한다. 복원된 메시의

watertightness 확보를 위해 Marching Cubes[9,10] 알고리즘을 적용하고, 정점 수가 10만개 이상인 경우 decimation을 통해 2만 vertex 이하의 low-poly 형태로 간소화한다.

2.4 파지 자세 생성

최종적으로, 후처리된 3D 메시를 입력으로 GHOP[5]을 활용하여 물체를 잡는 다양한 파지 자세를 생성한다. 최종 파지 자세는 3D 메시로 출력된다.

3. 결과

표 1: 각 단계별 출력 결과

Step Object	Egocentric Image + Gaze	Segmentation	3D Reconstruction	Grasp Synthesis
Wine glass				
Mug				

표 1은 제안된 시선 기반 2D 분할-3D 복원-그립 합성 파이프라인의 단계별 출력 결과를 보여준다. 시선 좌표를 이용한 분할과 복원, 그립 합성이 순차적으로 이루어졌다.




그림 2: 사용자 평가 결과

사용자 평가는 본 파이프라인의 실제 타당성을 검증하기 위해 수행되었다. 총 11명의 참여자(남 6, 여 4, 기타 1, 평균 연령 28.9세)가 총 3개의 물체(와인잔, 후라이팬, 머그컵)에 대해 이미지와 gif 파일 결과를 확인 후 5점 리커트 척도로 응답하였다. 전체 문항의 내적 일관성은 Cronbach's $\alpha=0.931$ 로 매우 높게 나타났다. 그림 2는 핵심 6개 항목의 평균 점수 ($\pm$ 표준편차)를 나타낸다. 시선 기반 입력과 각 단계별 결과에 관련된 항목인 '응시 적절성(4.24 ± 1.09)', '분할

품질(4.58 ± 0.79)', '3D 완전성(4.00 ± 1.00)', '물체 일관성(4.10 ± 1.10)'은 모두 평균 4점 내외로 높게 평가되었다. 이는 제안된 파이프라인이 시선 기반 객체 선택의 정확성, 2D 분할의 경계 정밀도, 그리고 단계 간 물체 일관성 측면에서 안정적으로 동작함을 보여준다. 특히 '분할 품질' 항목은 2D 분할 결과가 물체의 실제 경계를 대부분 정확히 포함한다는 점에서 가장 높은 평가를 받았다.

반면 '그립 타당성(3.00 ± 1.27)'과 '실사용 가능성(3.03 ± 1.16)'은 상대적으로 낮게 평가되었다. 참여자들은 손가락이 물체 내부로 침투하거나 접촉면이 비현실적으로 어긋나는 현상을 지적하였으며, 이는 GHOP 기반 그립 합성 과정에서 발생한 손가락 관통 및 접촉면 불일치에 기인한 것으로 보인다. 이 두 항목은 물체 유형에 따라 응답 차이가 커 표준편차가 각각 1.27, 1.16으로 다소 크게 나타났으며, 이는 물체에 따라 파지 결과가 다르게 인식되었음을 시사한다. 예를 들어, 손잡이가 넓고 긴 후라이팬에서는 비교적 자연스러운 파지가 이루어진 반면, 머그컵의 좁은 손잡이에서는 손가락 관통이 자주 발생하여 부자연스럽다는 평가가 많았다. 따라서 제안된 파이프라인이 물체 형상 복잡도에 따라 성능 편차가 존재함을 확인할 수 있었다.

표 2: 단계별 지연 시간 및 총 지연 시간

Step	Gaze Extraction	2D Seg	3D Recon	Grasp Synthesis	Total
Latency(s)	0.01	1.5	11.8	259	272.31

표 2는 단계별 지연 시간을 나타낸 것으로, 전체 처리 시간은 약 272.31초이며, 이 중 파지 자세 생성(259초) 단계가 대부분을 차지하였다.

4. 결론

본 연구에서는 시선 기반 객체 인식, 단일 이미지 기반 3D 복원, 그리고 파지 자세 생성을 통합한 엔드투엔드 파이프라인을 제안하였다. 사용자 평가 결과, 시선 기반 분할과 단계 간 일관성이 높게 평가되어 제안된 시스템의 시각적 타당성이 확인되었으며, 단일 이미지 입력만으로도 전반적으로 안정적인 파지 자세를 생성할 수 있음을 확인하였다. 다만 물체의 형태나 복잡도에 따라 성능 차이가 발생하고, Grasp Synthesis 단계의 연산 비용으로 인해 실시간성이 제한되는 한계가 존재한다. 향후 연구에서는 모델 경량화와 관통(penetration) 최소화를 위한 후처리 기법을 도입함으로써, 실제 로봇 제어나 VR 상호작용 시스템으로의 확장이 가능할 것으로 기대된다.

5. 참고문헌

[1] Y. Huang, X. Li, D. Held, and M. Cakmak, "What You See is What You Grasp: Learning Visual Representations for Robotic Grasping from Human Gaze," IEEE Robotics and Automation Letters, vol. 4, no. 3, pp. 3190–3197, 2019.

[2] A. Jalwana, D. Ye, M. Safaei, J. Zhang, S. Winkler, and G. Lin, "GazeGrasp: Gaze-Controlled Robotic Manipulation with Real-time 3D Gaze Estimation," Proceedings of the IEEE/ACM International Conference on Human-Robot Interaction (HRI), 2025. (To appear)

[3] D. Tochilkin, D. Pankratz, Z. Liu, Z. Huang, A. Letts, Y. Li, D. Liang, C. Laforte, V. Jampani, and Y.-P. Cao, "TripoSR: Fast 3D Object Reconstruction from a Single Image," arXiv preprint arXiv:2403.02151, 2024.

[4] R. Liu, R. Wu, J. J. Park, A. Holynski, and I. Kemelmacher-Shlizerman, "Zero-1-to-3: Zero-shot one image to 3d object," Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pp. 8470–8480, 2023.

[5] Y. Ye, A. Gupta, K. Kitani, and S. Tulsiani, "G-HOP: Generative Hand-Object Prior for Interaction Reconstruction and Grasp Synthesis," Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 1911–1920, 2024.

[6] H. Fang, C. Wang, M. Gou, Y. Liu, and C. Lu, "Graspnet-1billion: A large-scale benchmark for general object grasping," Proceedings of the IEEE/CVF conference on computer vision and pattern recognition (CVPR), pp. 11444–11453, 2020.

[7] C. Baumann and K. Dierkes, "Neon Accuracy Test Report," _Pupil Labs_, no. 10, 2023. [Online]. Available: <https://doi.org/10.5281/zenodo.10420388>

[8] A. Kirillov, E. Mintun, N. Ravi, H. Mao, C. Rolland, L. Gustafson, T. Xiao, S. Whitehead, A. C. Berg, W. Y. Lo, P. Dollár, and R. Girshick, "Segment Anything," Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pp. 3992–4003, 2023.

[9] W. E. Lorensen and H. E. Cline, "Marching Cubes: A High Resolution 3D Surface Construction Algorithm," ACM SIGGRAPH Computer Graphics, vol. 21, no. 4, pp. 163–169, 1987.

[10] T. Lewiner, H. Lopes, A. W. Vieira, and G. Tavares, "Efficient Implementation of Marching Cubes' Cases with Topological Guarantees," Journal of Graphics Tools, vol. 8, no. 2, pp. 1–15, 2003.